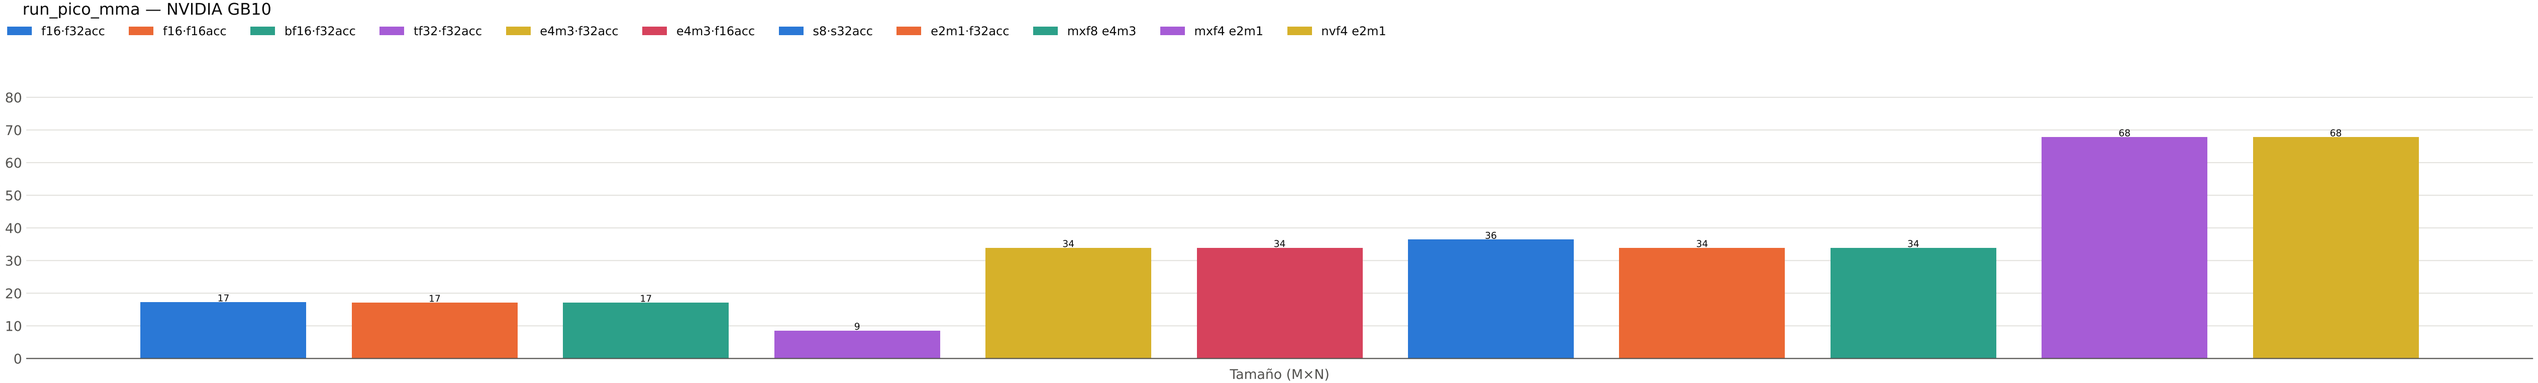
run_pico_mma — NVIDIA GB10
f16·f32acc
f16·f16acc
bf16·f32acc
tf32·f32acc
e4m3·f32acc
e4m3·f16acc
s8·s32acc
e2m1·f32acc
mxf8 e4m3
mxf4 e2m1
nvf4 e2m1
TFLOP/s (mayor es mejor)
0
10
20
30
40
50
60
70
80
17
17
17
9
34
34
36
34
34
68
68
Tamaño (M×N)
Barras: mediana (do_bench) y % del pico (línea). torch 2.9.0a0+145a3a7bda.nv25.10, triton 3.8.0, CUDA 13.0; job 21058.